

Лука Лехотски (ИН21-2023)

Поређење физички
информисаних неуралних
мрежа (PINN) са SINDy
алгоритмом у идентификацији
параметара пригушене опруге
(ПИНН СИНДИ)

Извештај

1. Увод

1.1. Предмет

Предмет овог рада је идентификација параметара динамичког система (коефицијента пригушења c и крутости опруге k) за пригушени хармонијски осцилатор. Пројекат се фокусира на директно поређење две супротстављене савремене методологије засноване на подацима (data-driven physics): алгоритме за регресију ретких матрица кроз SINDy (Sparse Identification of Nonlinear Dynamics) приступ и физички информисане неуралне мреже (PINN). Систем се тестира кроз три различита сценарија (чисти синтетички подаци, шумни неправилни подаци и реални индустријски подаци са Kaggle платформе).

1.2. Циљ

Циљ пројекта је детаљна евалуација робусности, тачности и практичне применљивости оба алгоритма при решавању инверзних проблема. Жели се емпиријски утврдити како се чисто математичко-симболички детерминистички приступ (SINDy) понаша у поређењу са стохастичким дубоким учењем (PINN) у условима када су улазни подаци деградирани високим степеном шума или су изразито малих амплитуда са великим временским хоризонтом.

1.3. Задаци

- Генерисање чистих синтетичких података (Dataset 1) помоћу нумеричког интегратора са минималним шумом (1%).
- Генерисање шумних података са неправилним временским размаком и високим степеном шума од 10% (Dataset 2) ради симулације лоших сензора.
- Учитавање, и прилагођавање реалног индустријског скупа података са Kaggle-а (Dataset 3) који карактерише дуг временски период и екстремно пригушење.
- Развој и архитектура PINN модела у PyTorch оквиру заснованог на интеграцији физичког губитка (Physics Loss) кроз аутоматско диференцирање.
- Имплементација SINDy анализе за издвајање структура експлицитних једначина динамике.
- Креирање обједињене скрипте (`comparison.py`) за упоредну визуелизацију временских трајекторија, грешака (MSE) и фазних портрета (Phase Space).

1.4. Очекивани резултати

Очекује се да ће на чистим подацима оба модела са високом тачношћу препознати параметре $c=0.5$ и $k=5.0$. На шумном скупу података (Dataset 2), очекује се предност PINN-а због уграђене регуларизације кроз диференцијалну једначину која потискује шум. За Dataset 3 се очекује идентификација скривене физике, при чему ће се јасно мапирати границе стабилности и рачунарске мане обе методе (осетљивост неуралне мреже на почетну иницијализацију тежина)

2. Методологија

2.1. Коришћени подаци

У раду су коришћена три различита скупа података смештена у `data/` директоријуму:

- **Dataset 1 (Синтетички чист):** Садржи 1000 еквидистантних тачака у временском домену од 0 до 20 секунди са додатком Гаусовог шума интензитета 1% од стандардне девијације сигнала.
- **Dataset 2 (Синтетички шумни и неправилни):** Садржи 400 насумично одабраних и неједнако временски распоређених тачака са високим степеном шума (10%). Овај скуп тестира понашање модела у условима губитка података.
- **Dataset 3 (Реални Kaggle подаци):** Скуп прикупљен са Kaggle платформе који садржи стварна мерења пригушеног осцилатора у трајању од преко 260 секунди. Овај скуп је специфичан јер амплитуде сигнала услед јаког пригушења падају на вредности веома малог реда величине, што представља огроман изазов за нумеричку стабилност модела.

2.2. Претходни слични подухвати других особа

Првобитни концепти за решавање инверзних проблема ослањали су се на класичну методу најмањих квадрата (OLS) и Калманове филтере, који имају огромне проблеме када структура модела није унапред савршено позната или када је присутна нелинеарност. Аутори попут Brunton-а (који је увео SINDy 2016. године) и Raissi-ја (који је дефинисао PINN 2019. године) направили су прекретницу унапређујући традиционалне инжењерске методе. Претходни радови показују да SINDy бриљира у експлицитној идентификацији облика једначина из богатих библиотека функција, док су PINN модели доказали супериорност у премошћавању јаза између парцијалних диференцијалних једначина и непотпуних мерних података.

2.3. Методе

Имплементирани су две кључне методе унутар раздвојених модула:

1. **SINDy (Sparse Identification of Nonlinear Dynamics):** Ослања се на конструкцију велике матрице кандидата за функције (полиноми, тригонометријске функције) и користи алгоритам секвенцијално праговисаних најмањих квадрата (STLSQ). Проналази најређи сет коефицијената који задовољава мерне изводе. Потпуно је детерминистички метод.
2. **PINN (Physics-Informed Neural Network):** Архитектура дубоке неуралне мреже оптимизована преко PyTorch фрејмворка. Њена функција губитка (Loss function) је модификована тако да поред стандардне MSE грешке на подацима рачуна и резидуал диференцијалне једначине система кроз аутоматско диференцирање (Autograd):

$$\text{Total Loss} = \text{Loss}_{\text{data}} + \lambda \cdot \text{Loss}_{\text{physics}}$$

Оптимизација се врши кроз 5000 епоха, при чему је унутар модела експлицитно фиксиран *Random Seed* како би се осигурала репродуктивност резултата.

3. Резултати

3.1. Приказ резултата

Након покретања комплексне упоредне анализе, алгоритми су за унапред дефинисане теоријске вредности ($c=0.5$, $k=5.0$) генерисали следеће вредности коефицијената на терминалима:

- **Dataset 1 (Чист сигнал):**
 - SINDy: $c = 0.5002$, $k = 5.0011$ (Изузетно ниска MSE грешка)
 - PINN: $c = 0.4991$, $k = 4.9982$
- **Dataset 2 (10% шума + неправилно време):**
 - SINDy: Показује благо одступање у параметрима услед тешкоћа при нумеричком рачунању извода над шумним и ретким сигналом.
 - PINN: Успешно филтрира шум и проналази параметре блиске теоријским вредностима захваљујући математичком "сидру" у виду једначине унутар Loss функције.
- **Dataset 3 (Kaggle подаци):**
 - SINDy успешно идентификује константе система без обзира на мале амплитуде.
 - PINN успешно конвергира ка решењу и прати фазни простор искључиво када је почетна насумична иницијализација тежина оптимизована, док у супротном тежи ка тривијалном локалном минимуму.

Сви графикони, укључујући реконструисане временске трајекторије (`comparison_dsX_trajectory.png`), реконструисане фазне портрете у координатама позиција-брзина (`comparison_dsX_phasespace.png`) и барове одступања за појединачне параметре успешно су сачувани у `plots/` директоријуму.

3.2. Тумачење резултата

Резултати су открили фундаменталне разлике у инжењерском понашању модела:

1. **Ефекат микро-амплитуда (Dataset 3):** С обзиром на то да Kaggle подаци у другом делу домена брзо опадају ка нули, MSE грешка PINN-а на тим вредностима је веома мала. Ово доводи до феномена "нестајућих градијената" (Vanishing Gradients) где мрежа добија лажну информацију да је грешка минимална, те је склона да уместо правог решења једноставно исцрта равну линију на нули.
2. **Фазни простори (Phase Space):** Приказивање резултата кроз фазне портрете (позиција наспрам брзине) показало је да SINDy реконструише правилне спирале пригушења у бесконачност, док PINN савршено пегла прелазне режиме, али је склон малим деформацијама у самој жижи фазног дијаграма где подаци потпуно замиру.

4. Закључак

4.1. Анализа испуњења циља

Постављени циљ пројекта је у потпуности испуњен. Сprovedено је ригорозно поређење детерминистичког симболичког модела и стохастичког модела дубоког учења. Анализа је јасно дефинисала границе примене: SINDy се показао као изванредан и невероватно брз алат када поседујемо експлицитне вредности стања (позиција и брзина), док је PINN демонстрирао своју надмоћ у условима великог шума (Dataset 2), делујући истовремено и као предиктивни модел и као филтер сигнала.

4.2. Анализа остварења очекиваних резултата

Сви очекивани резултати из спецификације идеје су остварени. Доказано је да PINN модел захваљујући физички информисаној природи не пати од "overfitting-a" чак и када су подаци ретки и неправилни. Међутим, откривена је и једна кључна мана дубоког учења која није била у потпуности предвиђена планом – изузетна осетљивост PINN-а на иницијализацију тежина (Random Seed) на дугим временским хоризонтима, што га чини непредвидљивим решењем у поређењу са традиционалном линеарном алгебром на којој почива SINDy.

4.3. Могућности за примену резултата у пракси

Развијени кодови и методологија могу се директно применити у реалним индустријским гранама:

- **Предиктивно одржавање (Predictive Maintenance):** Идентификација хабања механичких компоненти (промена коефицијента крутости k услед замора материјала опруге или промена вискозности η у амортизерима).
- **Аутомобилска индустрија:** Калибрација и симулација система ослањања возила на основу телеметријских података сакупљених са реалних возњи.
- **Роботика:** Моделовање динамике зглобова манипулатора који користе еластичне елементе.

4.4. Идеје за побољшање и даљу разраду

- **Увођење адаптивног скалирања губитка (Learning Rate Annealing):** Како би се решио проблем лоше конвергенције на Kaggle подацима, хиперпараметар пандерирања губитка требало би да се динамички мења током тренинга како физика не би надјачала стварне мерне податке.
- **Проширење библиотеке функција:** Модификација SINDy алгоритма увођењем нелинеарних чланова виших редова како би се идентификовало суво (Кулоново) трење или геометријске нелинеарности опруге.
- **Експеримент са редукованим информацијама:** Тестирање PINN-а у сценарију где је брзина потпуно недоступна у мерењима, чиме би се искористила његова способност да преко Autograd-а идентификује параметре само из сирових података о позицији, што SINDy не може без претходног нумеричког извођења.

5. Литература

- [1] Brunton, S. L., Proctor, J. L., & Kutz, J. N. (2016). Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *Proceedings of the National Academy of Sciences*, 113(15), 3932-3937.
- [2] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686-707.
- [3] Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3(6), 422-440.