

Поређење физички информисаних неуралних
мрежа (PINN) са SINDy алгоритмом у
идентификацији параметара пригушене опруге
(ПИНН СИНДИ)

АУТОР ПРОЈЕКТА

Лука Лехотски

Мотив пројекта: Системска идентификација



Одређивање једначине кретања Примарни циљ је математички описати стварно понашање физичког система у времену, проналажењем одговарајуће диференцијалне једначине.



Инверзни проблем у науци о подацима За разлику од директног проблема (предикција стања на основу једначине), овде решавамо инверзни задатак: из измерених временских серија (података) реконструишемо саму једначину и њене карактеристичне параметре.

Потребе и примене у индустрији

PINNs IN ACTION: VALUE FOR THE INDUSTRY




CHEMICAL REACTOR

PINNs run as a part of a hybrid model for a chemical reactor running the Fischer-Tropsch process.


Two PINNs are used to:

- Solve an equation for reaction rates.
- Model the distribution of reactants inside a catalytic pellet.




ELECTRICAL SUBMERSIBLE PUMPS

A digital twin of ESP-lifted oil well, based on PINN formalism, takes advantage of combining available sensor data with fluid flow equations, and the approximative power of neural networks.



MOLECULAR ELECTROSTATIC POTENTIAL

Our in-house PINN-based predictive pipeline is designed to produce a spatial distribution of molecular electrostatic potential for a wide range of organic molecules.



HEAT SINK DESIGN

Our PINN-driven solution for heat sink design solves heat transfer equations and optimizes heat sink configuration (e.g., temperature minimization on a CPU).

Научно машинско учење (SciML)



Физика вођена подацима

За разлику од чисто статистичког учења, **Data-Driven Physics** интегрише познате законе природе (нпр. одржање енергије) у архитектуру вештачке интелигенције ради стабилности.



Потрага за разумевањем

Избегавамо концепт "црних кутија". Циљ су нам **интерпретабилни модели** чије математичке изразе људи могу лако анализирати, разумети и верификовати у пракси.



Регулација и екстраполација

Интерпретабилност је услов за поуздано управљање (регулацију) и тачно предвиђање понашања ван граница снимљеног скупа података (екстраполација).


SINDy: Ретка идентификација динамике

 **Матрица функција-кандидата** Формира се библиотека кандидата која садржи линеарне, полиномне и тригонометријске нелинеарне чланове за једначину.

 **Ретка регресија (Sparse Regression)** Оптимизација одбацује све сувишне чланове из библиотеке, проналазећи само кључне који стварно управљају физичким системом.

 **Интерпретабилност модела** Резултат је експлицитна, лако читљива диференцијална једначина погодна за даљу анализу.

$$\dot{x} = \Theta(x) \Xi$$




PINN: Неуралне мреже вођене физиком

 **Интеграција физичких закона** Обична неурална мрежа се проширује тако што се познати физички закони (PDE/ODE) уводе директно у њен математички циљ.

 **Модификована функција губитка** Архитектура користи специјалну функцију губитка која истовремено кажњава одступање од мерења и нарушавање закона физике.

 **Аутоматско диференцирање (AD)** Користи се за прецизно израчунавање парцијалних извода кроз граф неуралне мреже без уношења нумеричких грешака.




СТРУКТУРА ПРОЈЕКТА


- **Генерисање података:** Симулација пригушеног хармонијског осцилатора (маса-опруга-пригушивач) за креирање чистих и шумљивих временских серија.
- **Имплементација SINDy алгоритма:** Поставка библиотеке нелинеарних функција-кандидата и примена ретке регресије за идентификацију релевантних чланова диференцијалне једначине.
- **Имплементација PINN модела:** Тренирање дубоке неуралне мреже уз модификацију функције губитка која кажњава одступања од физичког закона осцилатора.
- **Евалуација и поређење:** Анализа тачности, робусности на шум, рачунарске ефикасности и интерпретабилности добијених резултата оба модела.

PINN Analiza - Dataset 1 (1pct sum)


Vremenska serija




Fazni dijagram




Konvergencija treninga




Konvergencija prigušenja c



Konvergencija krutosti k




Distribucija reziduala




PINN Analiza - Dataset 2 (10pct sum)


Vremenska serija




Fazni dijagram




Konvergencija treniranja




Konvergencija prigušenja c



Konvergencija krutosti k




Distribucija reziduala




PINN Analiza - Dataset 3 (Kaggle)


Vremenska serija




Fazni dijagram




Konvergencija treninga




Konvergencija prigušenja c





Konvergencija krutosti k



Distribucija reziduala




ПОРЕЂЕЊЕ - СКУП ПОДАТАКА 1




ПОРЕЂЕЊЕ - СКУП ПОДАТАКА 2

Fazni portret (Phase Space) - Dataset 2 (10% šum, nepravilan)




Vremenska trajektorija $x(t)$ - Dataset 2 (10% šum, nepravilan)




ПОРЕЂЕЊЕ - СКУП ПОДАТАКА 3 (КАГГЛЕ)

Fazni portret (Phase Space) - Dataset 3 (Kaggle podaci)




Vremenska trajektorija x(t) - Dataset 3 (Kaggle podaci)




УКУПНО ПОРЕЂЕЊЕ


Identifikacija krutosti opruge k



Identifikacija koeficijenta prigušenja c



УКУПНО ПОРЕЂЕЊЕ



ЗАКЉУЧЦИ

- **Испуњење циља:** Успешно је извршено ригорозно поређење детерминистичког симболичког модела (SINDy) и стохастичког дубоког учења (PINN) кроз три комплексна сценарија.
- **Снаге SINDy алгоритма:** Показао се као невероватно брз и прецизан алат када су доступни чисти подаци о стањима.
- **Снаге PINN модела:** Демонстрирао је изразиту супериорност у условима високог шума од 10% и неправилних мерења (Dataset 2), делујући истовремено и као робустан филтер сигнала и као предиктивни модел.
- **Кључна мана дубоког учења:** Откривена је изузетна осетљивост PINN-а на почетну насумичну иницијализацију тежина (Random Seed) услед чега мрежа може да упадне у лажне локалне минимуме (проблем нестајућих градијената).
- **Практична примена:** Методологија је директно примењива у индустрији за предиктивно одржавање (детекција хабања амортизера и опруга), аутомобилску телеметрију и напредну роботiku.

ИДЕЈЕ ЗА НАПРЕДАК И ДАЉУ РАЗРАДУ

- **Адаптивно скалирање губитка (Learning Rate Annealing):** Увођење динамичког пондерисања компоненти у Loss функцији како би се спречило да физички резидуал надјача стварне мерне податке код јаког пригушења.
- **Проширење библиотеке функција:** Модификација SINDy алгоритма додавањем нелинеарних чланова виших редова ради идентификације сувог (Кулоновог) трења и геометријских нелинеарности реалних опруга.
- **Експеримент са редукованим информацијама:** Тестирање PINN-а у сценаријима где је брзина система потпуно недоступна у мерењима.

